ТРОИИ — конспект лекций

Преподаватель: Бурый Евгений Владиславович.

Конспект собран по рукописным записям и приведён в порядок: сокращения раскрыты, формулы переписаны, пропущенные шаги выводов восстановлены, описки исправлены. Добавленные мной пояснения вынесены в цитаты с пометкой **Пояснение**. Места, которые в рукописи не удалось прочитать однозначно, помечены **[?]**.

- Лекция 1 (03.03.26). Введение. Терминология. Признаки
- Справка: функция распределения и плотность вероятности
- Лекция 2 (10.03.26). Теория статистических решений для построения классификатора
- Лекция 3 (17.03.26). Минимаксная стратегия. Алгоритмы классификации. Нейрон
- Лекция 4 (24.03.26) и далее. Нейронные сети и их обучение
- Краткая сводка

Лекция 1 (03.03.26). Введение. Терминология. Признаки

1.1. Что такое ИИ

Искусственный интеллект (ИИ) — технология, имитирующая человеческое поведение, чтобы выполнять задачи и обучаться. Это способность машины (системы) выполнять действия, свойственные человеческому интеллекту.

- **Зачем?** — чтобы эффективно выполнять задачи.
- ИИ имитирует человека в задачах обработки информации (пример — опрос людей).

Формальная постановка. Есть вектор X из параметров — свойств объектов. Ему в соответствие ставится вектор Y, зависящий от управляемых [?] и неизвестных входных параметров. Векторы X и Y однозначно связаны друг с другом, если между ними есть функциональная зависимость $Y = F(X)$.

При этом возможна ситуация $Y = \text{const}$ при $X \neq \text{const}$: разным векторам X соответствует один и тот же Y.

> **Пояснение.** Именно это и есть суть распознавания: много разных наблюдений X (один и тот же самолёт под разными ракурсами, с шумом и т. п.) должны быть отображены в один ответ Y — номер класса.

1.2. Терминология

Термин	Определение
Распознавание	Выделение характерных черт объекта; совокупность действий, производимых с целью получения интересующей информации об объекте исследования.
Признак	Характерная черта объекта.
Словарь признаков	Совокупность информативных признаков, определяющих объект.
Вектор признаков	Совокупность чисел, однозначно отличающая один объект от другого.
Пространство признаков	Пространство, в котором определены векторы признаков.
Редукция пространства признаков	Процедура, обеспечивающая уменьшение размерности пространства признаков.
Образ	Совокупность характеристик объекта, образующих вектор признаков, представляющий этот объект в информационном пространстве (пространстве признаков).
Класс	Совокупность объектов, имеющих некоторые общие свойства.
Алфавит классов	Определённым образом упорядоченное множество классов.
Классификация	Процедура, обеспечивающая отнесение исследуемого объекта к одному из классов.
Кластер (скопление, гроздь, рой)	Совокупность сходных объектов.
Кластеризация	Процедура разбиения объектов на группы (кластеры) так, что объекты разных групп сильно отличаются друг от друга. Кластеры не задаются заранее — в отличие от классов.
Селекция	Процедура выделения (интересующих объектов) из множества [?].
Качество распознавания	Характеристика системы, отражающая её возможность работать в условиях шумов и помех.
Устойчивость распознавания	Сохранение работоспособности системы распознавания при изменении в определённых пределах параметров объектов и условий функционирования.

1.3. Кластерный анализ

Дано множество объектов X и множество номеров кластеров Y. Задаётся функция расстояния между объектами $\rho(x, x')$, на основе которой обучающую выборку нужно разбить на кластеры так, чтобы:

- каждый кластер состоял из объектов, **близких** по метрике ρ;
- объекты **разных** кластеров существенно различались.

Области применения кластеризации:

- маркетинг — сегментирование клиентов, конкурентов, исследование рынков;

- медицина — классификация симптомов, заболеваний, препаратов;
- биология — классификация живых организмов;
- социология — разбиение респондентов на однородные группы;
- компьютерный поиск — группировка результатов поиска сайтов, файлов.

Кластеризация особенно актуальна, если исходная выборка слишком большая: в результате в каждом кластере можно оставить по одному типичному представителю (сжатие данных).

1.4. Формирование образов объектов, их кластеризация и распознавание

Пример. Поставлена задача классификации типов летательных аппаратов (ЛА) в соответствии с их принадлежностью и возможной опасностью для охраняемого объекта.

- **МиГ-31**, ракурс $\alpha = 0^\circ,\ \beta = 0^\circ$: измеряем признаки $1, 2, \ldots, N$ и формируем вектор признаков **1.1**. При $\alpha = 10^\circ$ получаем вектор **1.2**, при $\alpha = 20^\circ$ — вектор **1.3**. Набор векторов 1.1, 1.2, 1.3 составляет **образ 1**.
- **F-16**, аналогично: $\alpha = 0^\circ \to 2.1$, $\alpha = 10^\circ \to 2.2$, $\alpha = 20^\circ \to 2.3$. Набор составляет **образ 2**.

Имеются априорные сведения, что в зоне ответственности всего могут появиться 15 типов ЛА. Образы формируются для каждого из них.

Кластеризация 15 типов:

Типы ЛА	Кластер
1 … 7	истребители
8, 9, 12	бомбардировщики
10, 11, 13	транспортные [?]
14, 15	прочие

Далее возможна **уточняющая кластеризация** внутри полученных групп.

Структурная схема системы:



Не существует универсальной системы распознавания — система строится под конкретную задачу.

1.5. Функции классификатора

№	Функция	Обязательность
1	Получение первичной информации об объекте	обязательно (+)
2	Селекция интересующих объектов	необязательно (−)
3	Формирование первичного вектора признаков	обязательно (+)
4	Редукция пространства признаков	необязательно (−)
5	Классификация вектора информативных признаков	обязательно (+)
6	Оценка правдоподобности результата	необязательно (−)



1.6. Информативные признаки

Виды признаков:

1. **Физические** — наблюдаемые и измеряемые. *Пример:* длина L, ширина W, высота H, масса m.
2. **Структурные** — результат анализа совокупности физических признаков. *Пример:* форма (цилиндр или параллелепипед), цвет; для ЛА — скорость 150–200 км/ч [?].

3. **Математические** — получаются в результате выполнения математических операций над рядом физических или структурных признаков. *Пример:* плотность $\rho = \frac{m}{L \cdot W \cdot H}$; множество отсчётов зарегистрированного сигнала (сигнатура) [?].

Требования к признакам:

- соответствие целевой задаче распознавания;
- индивидуальность — различие значений для разных объектов;
- инвариантность к условиям наблюдения;
- непрерывность (устойчивость) по отношению к условиям наблюдения.

Проблема выбора признаков заключается в сокращении числа признаков и размерности пространства признаков без потери качества распознавания.

Признаки делятся на **главные** и **второстепенные** (частные, в т. ч. не присущие объекту непосредственно). Физические признаки должны быть доступны для оценивания в различных условиях наблюдения.

Детерминированные и статистические признаки:

- **Детерминированные** — непрерывные и логические (знаковые) [?]. Примеры: а) установлено, что форма — круг; б) установлено, что объект отличен от параллелепипеда.
- **Статистические** — получаются регистрацией параметров в моменты времени t_i и описываются вероятностными характеристиками.

Справка: функция распределения и плотность вероятности

Функция распределения случайной величины X:

$$F(x) = P(X < x), \qquad X \in (-\infty;\ x).$$

Свойства:

- $F(-\infty) = 0$;
- $F(x)$ — неубывающая;
- $F(+\infty) = 1$.

Функция плотности вероятности $W(x)$ существует, если $F(x)$ дифференцируема:

$$W(x) = \frac{dF(x)}{dx} \geq 0, \qquad \int_{-\infty}^{+\infty} W(x)\,dx = 1 \quad \text{(условие нормировки)}.$$

Вероятность попадания в интервал:

$$P(x_1 \leq X \leq x_2) = F(x_2) - F(x_1) = \int_{x_1}^{x_2} W(x)\,dx.$$

- Размерность $W(x)$ обратна размерности X.
- Зная $W(x)$, можно сказать, какие значения величины наиболее вероятны.

Лекция 2 (10.03.26). Теория статистических решений для построения классификатора

2.1. Постановка задачи

- Имеется множество из N объектов $\{\Omega_1, \ldots, \Omega_N\}$.
- В соответствии с принципом деления они разбиты на классы $\{A_1, \ldots, A_M\}$.
- Известны информативные признаки объектов $\{x_1, \ldots, x_n\}$.
- Классы описаны априори через признаки:

$$\begin{cases} A_1 = F_1(x_1, \ldots, x_n) \\ \quad \vdots \\ A_M = F_M(x_1, \ldots, x_n) \end{cases}$$

Нужно определить, к какому классу относится объект.

Может быть принято $M + 1$ решение: M решений «объект принадлежит классу A_i» и ещё одно — **отказ**, когда объект не может быть отнесён ни к одному классу.

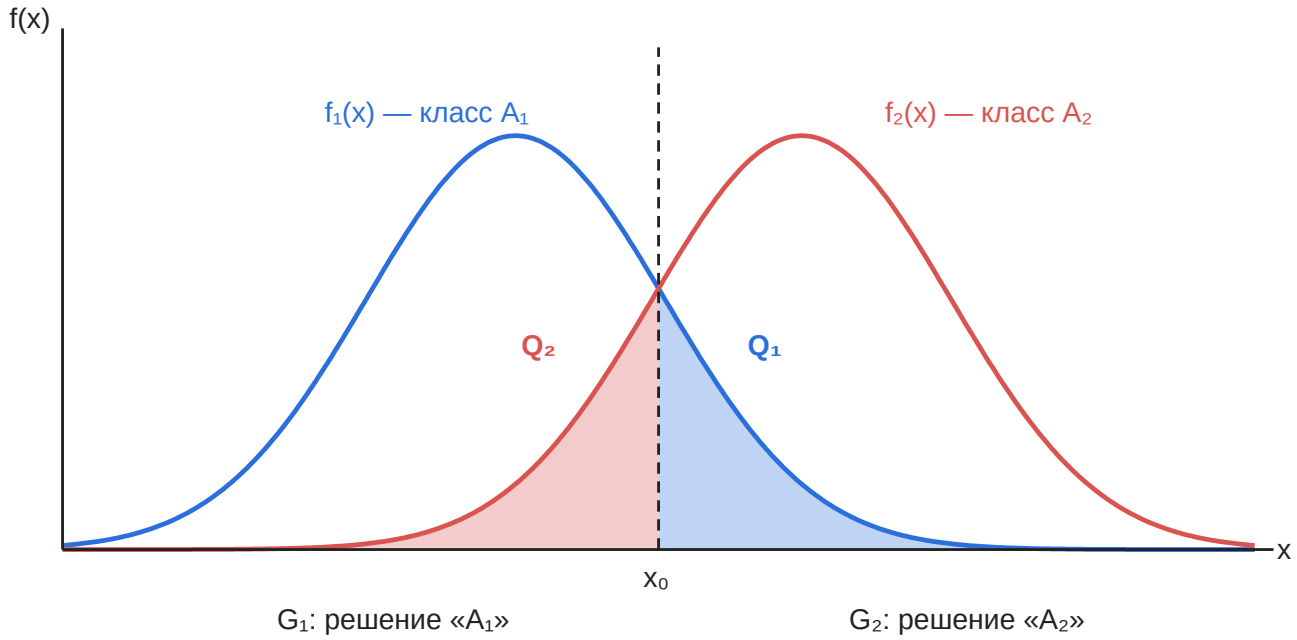
Из-за шумов и помех невозможно безошибочно определить параметры объектов, поэтому **задача распознавания — вероятностная**.

2.2. Два класса, один признак

Дано: 2 объекта (Ω_1, Ω_2), 2 класса A_1 и A_2;

- $f_1(x)$ и $f_2(x)$ — плотности вероятности появления признака x у объектов классов A_1 и A_2 ;
- $P(A_1)$, $P(A_2)$ — априорные вероятности появления объектов каждого класса.

Порог x_0 делит пространство признаков на два подпространства: G_1 (решение «A_1») и G_2 (решение «A_2»). Значение x_0 нужно выбрать так, чтобы условные вероятности ошибок 1-го рода ($\Omega_1 \to A_2$) и 2-го рода ($\Omega_2 \to A_1$) были минимальны.



Вероятности ошибок и правильных решений:

$$Q_1 = \int_{x_0}^{+\infty} f_1(x)\,dx, \qquad D_1 = 1 - Q_1;$$

$$Q_2 = \int_{-\infty}^{x_0} f_2(x)\,dx, \qquad D_2 = 1 - Q_2.$$

Здесь Q_1 — вероятность ошибки 1-го рода, Q_2 — 2-го рода, D_1, D_2 — вероятности правильного распознавания.

2.3. Матрица потерь и средний риск

Матрица потерь (строка — истинный класс, столбец — принятое решение):

$$\|C\| = \begin{bmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{bmatrix}$$

- Элементы главной диагонали — нулевые или отрицательные: это потери при **правильных** решениях.
- Все остальные — потери при **ошибочных** решениях (C_{12} — объект класса A_1 отнесён к A_2, C_{21} — наоборот).

Средний риск:

$$R(x_0) = P(A_1)\,(C_{11}D_1 + C_{12}Q_1) + P(A_2)\,(C_{22}D_2 + C_{21}Q_2)\,.$$

Минимизация. Учитывая, что $\dfrac{dQ_1}{dx_0} = -f_1(x_0)$, $\dfrac{dD_1}{dx_0} = f_1(x_0)$, $\dfrac{dQ_2}{dx_0} = f_2(x_0)$, $\dfrac{dD_2}{dx_0} = -f_2(x_0)$:

$$\frac{dR}{dx_0} = P(A_1)\big(C_{11}f_1(x_0) - C_{12}f_1(x_0)\big) + P(A_2)\big(C_{21}f_2(x_0) - C_{22}f_2(x_0)\big) = 0.$$

Отсюда

$$\boxed{\lambda_0 = \frac{f_2(x_0)}{f_1(x_0)} = \frac{P(A_1)\,(C_{12} - C_{11})}{P(A_2)\,(C_{21} - C_{22})}}$$

- $\lambda(x) = \dfrac{f_2(x)}{f_1(x)}$ — **отношение правдоподобия**;
- $\lambda_0 = \dfrac{P(A_1)}{P(A_2)} \cdot \dfrac{C_{12} - C_{11}}{C_{21} - C_{22}}$ — **порог**.

Решающее правило: если $\lambda(x) > \lambda_0$ — объект относится к классу A_2, иначе — к классу A_1.

> **Пояснение.** Порог зависит только от априорных вероятностей и матрицы потерь. Если ошибка «пропустить A_2» дороже (растёт C_{21}), порог λ_0 уменьшается и система чаще выдаёт решение «A_2».

2.4. Пример: два гауссовских класса

- $f_1(x), f_2(x)$ — нормальные плотности с матожиданиями m_1 и m_2;
- дисперсии равны: $\sigma_1^2 = \sigma_2^2 = \sigma^2$;
- $P(A_1) = P(A_2)$;
- $C_{11} = C_{22}$, $C_{12} = C_{21}$.

Тогда $\lambda_0 = 1$, т. е. порог — точка пересечения плотностей:

$$x_0 = \frac{m_1 + m_2}{2}.$$

Такая стратегия выбора порога называется **байесовской стратегией принятия решений**.

> **Пояснение (вывод).** $\lambda(x_0) = 1 \Rightarrow (x_0 - m_1)^2 = (x_0 - m_2)^2 \Rightarrow x_0 = \frac{m_1+m_2}{2}$.

2.5. Общий случай: $M \geq 2$ классов, вектор признаков

Вектор признаков $X = \{x_1, \ldots, x_n\}$, $f_k(X)$ — плотность распределения X для класса A_k.

Отношения правдоподобия:

$$\lambda_{kl} = \frac{f_k(X)}{f_l(X)}, \qquad k = 1 \ldots M, \quad l = 1 \ldots M.$$

Матрица потерь размером $M \times M$:

$$\|C\| = \begin{bmatrix} C_{11} & \cdots & C_{1M} \\ \vdots & \ddots & \vdots \\ C_{M1} & \cdots & C_{MM} \end{bmatrix}$$

Средний риск (G_k — область пространства признаков, в которой принимается решение «класс A_k»):

$$R = \sum_{k=1}^{M} \sum_{l=1}^{M} P(A_l)\, C_{lk} \int_{G_k} f_l(X)\, dX.$$

> В рукописи индексы потерь записаны как C_{kl}; здесь они приведены к тому же соглашению, что и в п. 2.3: первый индекс — истинный класс, второй — принятое решение.

Решающее условие минимизации среднего риска (граница между областями G_k и G_l):

$$P(A_k)\, f_k(X)\,(C_{kl} - C_{kk}) - P(A_l)\, f_l(X)\,(C_{lk} - C_{ll}) = 0.$$

Простая (единичная) функция потерь: $C_{kk} = C_{ll} = 0$, $C_{kl} = C_{lk} = 1$. Тогда

$$P(A_k)\, f_k(X) - P(A_l)\, f_l(X) = 0 \quad \Longleftrightarrow \quad \ln \frac{P(A_k)\, f_k(X)}{P(A_l)\, f_l(X)} = 0.$$

> **Пояснение.** Отсюда решающее правило: объект относится к классу A_k, у которого произведение $P(A_k)\, f_k(X)$ максимально, т. е. максимальна апостериорная вероятность $P(A_k \mid X)$. При единичных потерях минимум среднего риска совпадает с минимумом вероятности ошибки. Логарифм удобен для гауссовских плотностей: экспоненты превращаются в квадратичные формы.

Условия применимости. Байесовский классификатор можно построить, если известны:

1. плотности распределения вероятности признаков $f_i(X) = f(X \mid A_i)$ для каждого класса;
2. априорные вероятности $P(A_i)$, $i = 1, 2, \ldots, M$;
3. матрица потерь $\|C\|$.

Лекция 3 (17.03.26). Минимаксная стратегия. Алгоритмы классификации. Нейрон

> В шапке страницы записано «ЛЗ. Нейросетевые технологии»; первая половина лекции продолжает теорию статистических решений.

3.1. Гарантирующая (минимаксная) стратегия

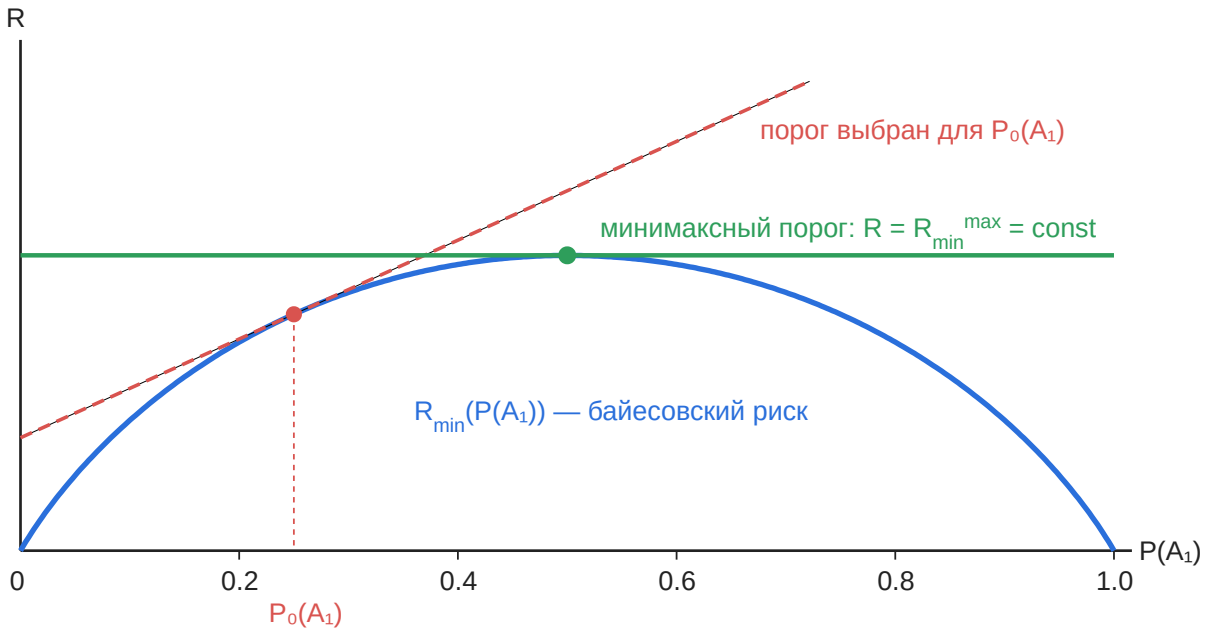
Если априорные вероятности появления объектов каждого класса $P(A_i)$ **неизвестны**, используют **минимаксную стратегию**, гарантирующую определённое значение среднего риска. Порог выбирают так, чтобы минимизировать риск при **наихудших** значениях априорных вероятностей — тех, при которых риск максимален.

Два класса. $P(A_2) = 1 - P(A_1)$, $C_{11} = C_{22} = 0$, $C_{12}, C_{21} \neq 0$. Тогда

$$R = P(A_1)\,C_{12}\int_{x_0}^{+\infty} f_1(x)\,dx + \big(1 - P(A_1)\big)\,C_{21}\int_{-\infty}^{x_0} f_2(x)\,dx = P(A_1)\big(C_{12}Q_1 - C_{21}Q_2\big) + C_{21}Q_2,$$

где Q_1, Q_2 — вероятности ошибок 1-го и 2-го рода при пороге x_0.

Если для каждого $P(A_1)$ брать оптимальный (байесовский) порог, получаем минимальный риск $R_{\min} = f\big(P(A_1)\big)$. Отметим, что $R_{\min} = 0$ при $P(A_1) = 0$ и при $P(A_1) = 1$, а между ними кривая выпукла вверх и имеет максимум $R_{\min}^{\max}$ в точке $P_0(A_1)$.



- Если порог рассчитан для некоторого $P_0(A_1)$, а истинная вероятность $P(A_1)$ другая, то риск меняется **по прямой** (касательной к кривой $R_{\min}$ в точке $P_0(A_1)$).
- Если взять $P_0(A_1)$ не в точке максимума, то на одном участке риск будет меньше $R_{\min}^{\max}$, а на другом — превысит его.
- **Минимаксный выбор:** $P_0(A_1)$ берут в точке максимума $R_{\min}$. Там касательная горизонтальна, т. е. риск **не зависит** от истинной $P(A_1)$ и всегда равен $R_{\min}^{\max}$. Условие:

$$C_{12}\,Q_1(x_0) - C_{21}\,Q_2(x_0) = 0.$$

Пороговое значение отношения правдоподобия при этом

$$\lambda_0 = \frac{C_{12}\,P_0(A_1)}{C_{21}\left(1 - P_0(A_1)\right)}.$$

- При $C_{12} = C_{21}$ условие сводится к **равенству вероятностей ошибок 1-го и 2-го рода**: $Q_1 = Q_2$.
- Решающее правило: $\Omega \in A_1$, если $x < x_0$; $\Omega \in A_2$, если $x \geq x_0$.

Минимаксная стратегия — это стратегия Байеса для наихудших значений априорных вероятностей.

3.2. Алгоритмы классификации

Рассматривают, как правило, два случая: число классов **задано** и число классов **неизвестно**.

Задача: распределить N объектов по M классам так, чтобы обеспечить экстремум некоторого **критерия эффективности**.

Для оптимальной классификации нужно перебрать все возможные варианты разбиения, что при больших M и N нереально. Поэтому сокращают число рассматриваемых (неперспективных) вариантов и используют **итеративные алгоритмы**, в ходе которых оценивается критерий эффективности разных вариантов разбиения на классы.

Итеративный алгоритм (число классов задано):

1. Определить начальное множество (алфавит) классов.
2. Вычислить значение исходного критерия эффективности E_0.
3. Поочерёдно перемещать объекты из класса A_i в класс A_j ($i, j = 1, 2, \ldots, M$) и на каждом шаге вычислять значение критерия E_{ij}.
4. Если существует $E_{ij} > E_0$ — переформировать алфавит классов и повторить п. 2–4. Если переформирование не требуется — процедура завершается.

Нет гарантии, что алгоритм достигнет **абсолютного (глобального)** максимума эффективности: результат зависит от начального разбиения и от возможного неудачного выбора числа классов.

3.3. Классификация при неизвестном числе классов

Число классов определяется в процессе классификации. Два основных метода:

1) Алгоритм последовательного увеличения числа классов. Число классов K наращивают по одному; на каждом шаге объекты распределяют по K классам так, чтобы обеспечить максимальную эффективность распознавания. Процедура повторяется, пока эффективность распознавания возрастает. [?]

2) Алгоритм последовательного объединения классов.

- Пусть имеется N объектов (вначале каждый — отдельный класс).

- Формируются все алфавиты из $M = N - 1$ классов (объединяется одна пара) и для каждого оценивается эффективность Э. Число таких вариантов A^{N-1} равно C_N^2.
- Из лучшего A^{N-1} формируется множество алфавитов A^{N-2}; их число C_{N-1}^2.
- Затем $A^{N-2} \to A^{N-3}$ и т. д., пока **уменьшение числа классов K сопровождается ростом эффективности распознавания**.

Пример: 5 объектов. Варианты на 4 класса ($Э_i^4$ — эффективность i-го варианта):

Вариант	**I**	**II**	**III**	**IV**
$Э_1^4$	1	2	3, 5	4
$Э_2^4$	1	2	3	4, 5
$Э_3^4$	1, 5	2	3	4
…				

Всего вариантов $C_5^2 = 10$. Далее — 3 класса:

Вариант	**I**	**II**	**III**
$Э_1^3$	1, 4	2	3, 5
$Э_2^3$	1, 4	2, 5	3
$Э_3^3$	1, 5	2, 4	3

И 2 класса:

Вариант	**I**	**II**
$Э_1^2$	1, 3, 5	2, 4
$Э_2^2$	… [?]	…

На каждом шаге выбирается вариант с максимальной эффективностью; объединение прекращается, когда эффективность перестаёт расти.

3.4. Искусственные нейронные сети: биологический прототип



Исторически биологический нейрон послужил основой для создания искусственных нейронных сетей (ИНС). Вместе с тем свойства биологических прототипов существенно превышают возможности ИНС.

- **Синапс** — «контакт» одной клетки с другой.
- **Аксон** — «проводник» клетки (длина ≈ 0,1–1000 мм).
- **Дендриты** — входы воздействий на клетку.

Электрохимия клетки. В невозбуждённом состоянии потенциал клетки относительно окружающей среды ≈ **−70 мВ**. Его поддерживают ионные насосы (до 10^6 на клетку): каждый перекачивает ≈ 200 ионов Na^+/с и ≈ 130 ионов K^+/с. Получение нейротрансмиттерных

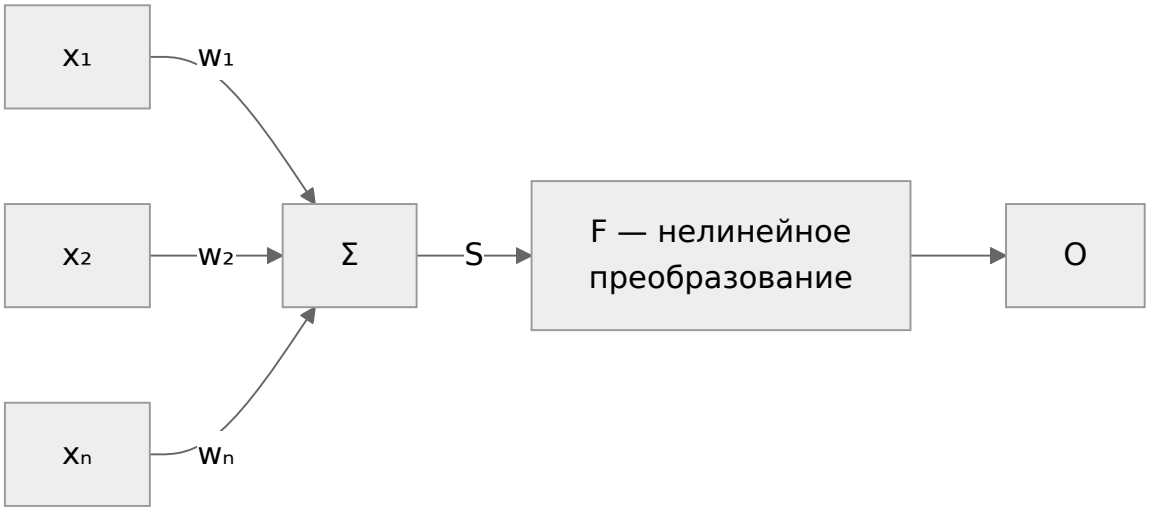
молекул мембраной клетки вызывает переход в **возбуждённое состояние** (≈ +60 мВ [?]).

Синаптическая передача. Специальные химические вещества — **нейротрансмиттеры** — выделяются под действием импульса в **синаптическую щель**, отделяющую аксон одной клетки от дендрита другой. Синаптическое окончание аксона — небольшое утолщение со сферическими структурами (везикулами), содержащими большое число нейротрансмиттерных молекул. Под действием электрического импульса, пришедшего по аксону, эти молекулы высвобождаются в синаптическую щель.

- В биологических НС два типа связи: **химическая** — между нейронами, **электрическая** — внутри нейрона.
- Поток информации — **импульсно-модулированный**.
- Эффективность НС зависит от количества нейронов и **в большей степени — от их связей**.

3.5. Искусственный нейрон

Искусственный нейрон (ИН) в первом приближении соответствует биологическому прототипу.

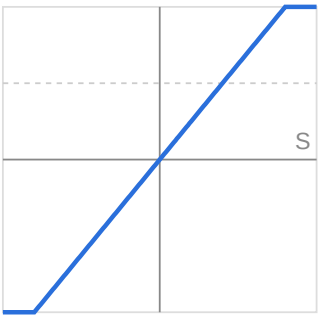


$$S = X \cdot W = \sum_{i=1}^{n} x_i w_i, \qquad O = F(S).$$

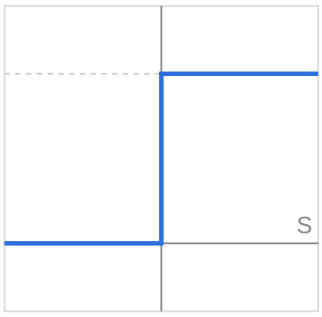
F — **активационная функция**: нелинейная функция от воздействия на входе этого модуля.

Вид	Формула
Линейная	$F(S) = kS$
Пороговая	$F(S) = 1$ при $S \geq \Theta$; $F(S) = 0$ при $S < \Theta$
Сигмоида (логистическая)	$F(S) = \dfrac{1}{1 + e^{-S}}$
Гиперболический тангенс	$F(S) = \mathrm{th}(S)$

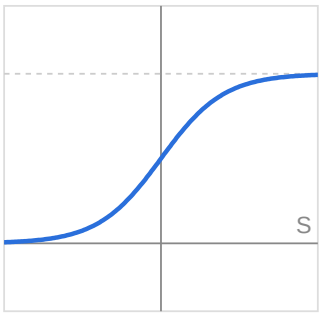
Линейная F = kS



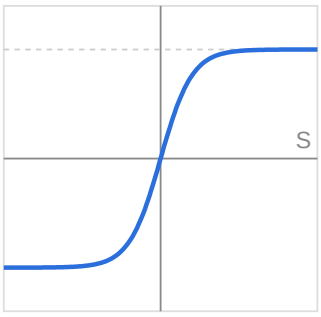
Пороговая



Сигмоида $1/(1+e^{-s})$



th(S)

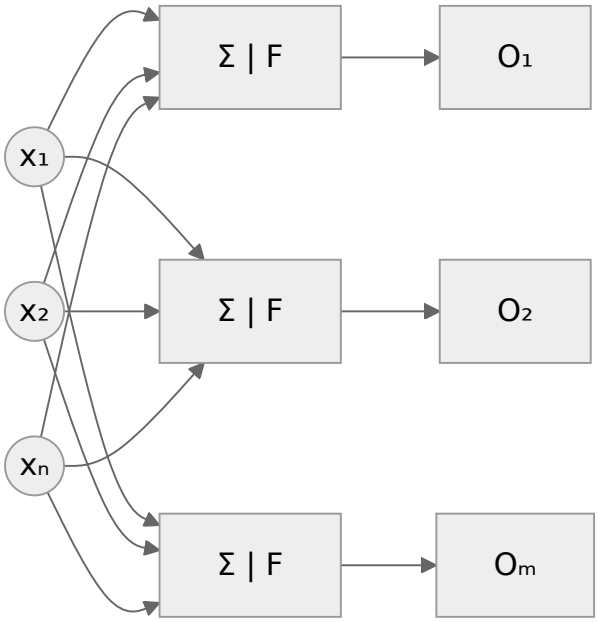


Лекция 4 (24.03.26) и далее. Нейронные сети и их обучение

> Страницы после записи «Л4. 24.03.26» в конспекте не датированы, поэтому всё оставшееся собрано в эту главу.

4.1. Однослойные нейронные сети

Каждый вход связан со всеми m нейронами слоя:



$$O = F(X \cdot W),$$

W — матрица весов: число строк равно числу входов НС, число столбцов — числу нейронов.

- **Представляемость** — способность сети моделировать ту или иную функцию связи векторов X и O.
- **Обучаемость** — существование процедуры выбора (подбора) матрицы коэффициентов W, которая реализует представимую функцию связи.

4.2. Пример: «Исключающее ИЛИ» (XOR) и линейная разделимость

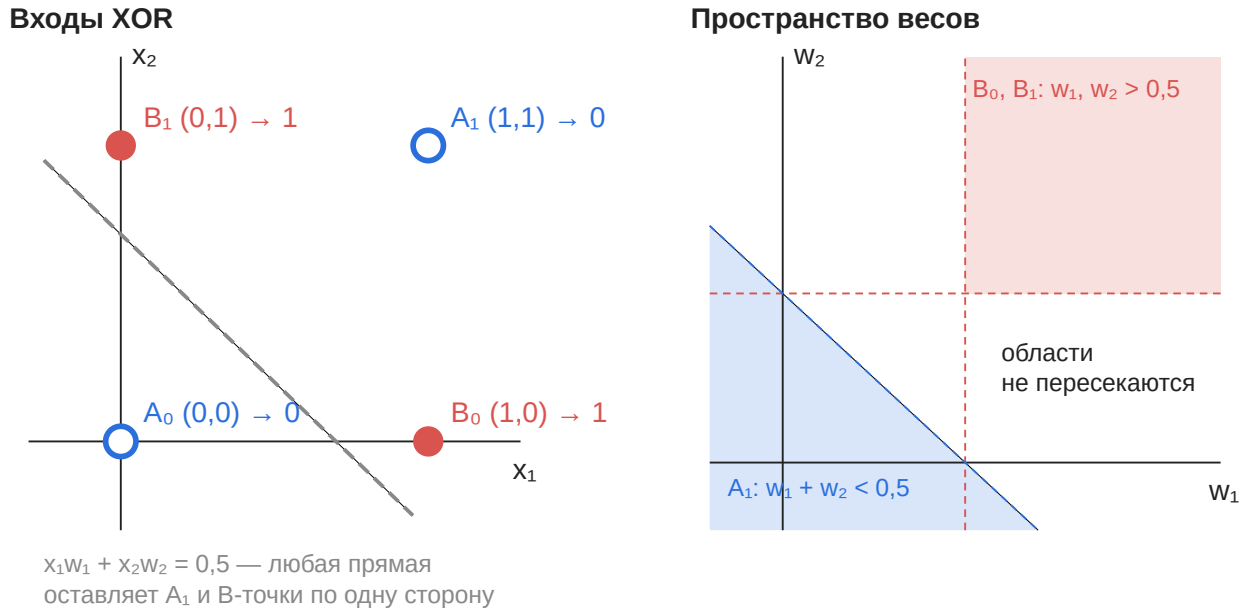
Один нейрон с двумя входами и пороговой функцией:

$$F(S) = 1 \text{ при } S > 0{,}5; \qquad F(S) = 0 \text{ при } S < 0{,}5; \qquad y = F(x_1 w_1 + x_2 w_2).$$

Точка	x_1	x_2	$x_1 \oplus x_2$
A_0	0	0	0
B_0	1	0	1
B_1	0	1	1
A_1	1	1	0

Граница решения $x_1 w_1 + x_2 w_2 = 0{,}5$ — прямая. Чтобы реализовать XOR, она должна отделить точки B_0, B_1 от A_0, A_1, лежащих в противоположных углах квадрата. **Это невозможно.**

> **Пояснение (через веса).** B_0 требует $w_1 > 0{,}5$, B_1 — $w_2 > 0{,}5$, а A_1 — $w_1 + w_2 < 0{,}5$. Первые два условия дают $w_1 + w_2 > 1$ — противоречие.



4.3. Классический персептрон

Персептрон (от лат. *perceptio* — восприятие) — однослойная сеть из пороговых нейронов.

- 2 входа — разделяющая граница **прямая**, 3 входа — **плоскость**, n входов — **гиперплоскость** в n-мерном пространстве.
- Два множества точек в n-мерном пространстве **линейно разделимы**, если их можно разделить одной $(n-1)$-мерной гиперплоскостью.

Доля линейно разделимых среди всех логических функций n переменных быстро падает:

n	**Число двоичных функций 2^{2^n}**	**Число линейно разделимых**	**Доля**
1	4	4	1
2	16	14	0,88
3	256	104	0,41
4	65 536	1 882	0,03
5	$4{,}3 \cdot 10^9$	94 572	$\approx 2 \cdot 10^{-5}$
6	$1{,}8 \cdot 10^{19}$	15 028 134	$\approx 8 \cdot 10^{-13}$

> В рукописи в последнем столбце для $n = 5, 6$ стоят 10^{-3} и 10^{-10} [?]; здесь — значения, пересчитанные по двум первым столбцам.

Вывод: представляемость однослойной НС недостаточна.

Обучение персептрона — обучение с учителем на обучающем множестве:

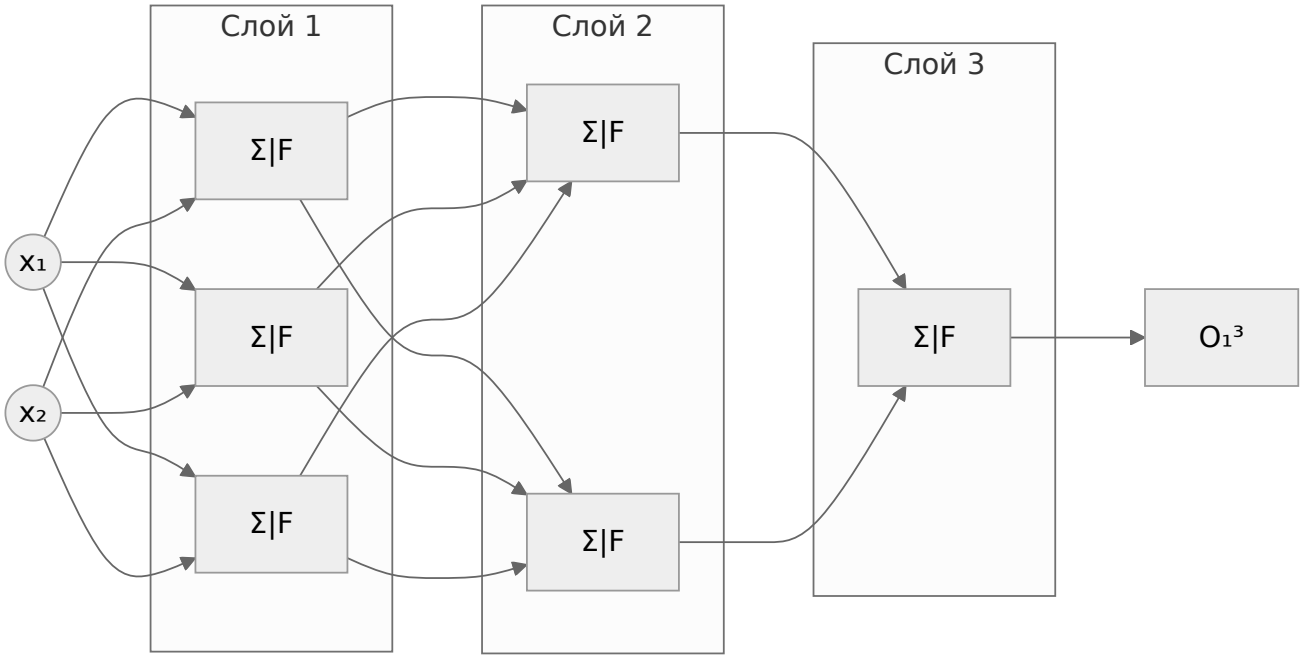
1. Подать входной вектор X.
2. Вычислить выход O.
3. Если результат ошибочен — скорректировать весовые коэффициенты:

$$\delta = T - O, \qquad \Delta_i = \eta\,\delta\,x_i, \qquad w_i(n+1) = w_i(n) + \Delta_i,$$

где T — требуемый (целевой) выход, η — коэффициент скорости обучения.

4.4. Многослойные НС. Преодоление линейной разделимости

- **1 слой:** каждый нейрон делит пространство прямой (гиперплоскостью) на две полуплоскости.
- **2 слоя:** нейрон 2-го слоя комбинирует полуплоскости — получается **выпуклая** область (многоугольник), например пересечение двух полуплоскостей.
- **3 слоя:** нейрон 3-го слоя комбинирует выпуклые области — получаются области **сложной формы, в том числе невыпуклые** (выпукло-вогнутые).



> **Пояснение.** XOR решается уже двухслойной сетью: два нейрона первого слоя проводят две параллельные прямые, нейрон второго слоя выделяет полосу между ними, в которую попадают B_0 и B_1.

4.5. Алгоритм обратного распространения ошибки (backpropagation)

Цель обучения — такая настройка весов НС, при которой предъявление входных векторов приводит к формированию требуемых выходных векторов. При обучении каждому входному вектору ставится в соответствие целевой выходной вектор (обучающая пара).

1. Перед началом весам задаются начальные значения (малые случайные).
2. Выбирается обучающая пара: входной вектор и соответствующий ему целевой.

3. Вычисляются выходы НС — компоненты выходного вектора.
4. Вычисляется вектор ошибки — разность между целевым вектором T и выходом НС.
5. Корректируются весовые коэффициенты так, чтобы ошибка уменьшилась.
6. Возврат к п. 2, если ошибка превышает заданный уровень.

Структура: вход $X \to$ слой 1 (M^1 нейронов) $\to \ldots \to$ слой $n-2 \to$ слой $n-1 \to$ слой $n \to$ выход O^n, сравниваемый с целью T. w_{ij}^n — вес связи i-го нейрона слоя $n-1$ с j-м нейроном слоя n.

1. Проход вперёд — вычисление выходов слоёв:

$$O^1 = F\big(X\,W^1\big), \quad O^2 = F\big(O^1 W^2\big), \quad \ldots, \quad O^n = F\big(O^{n-1} W^n\big).$$

O и X — векторы-строки. W^k — матрица коэффициентов k-го слоя: число строк равно числу входов слоя, число столбцов — числу выходов, т. е. числу нейронов в слое.

2. Проход назад.

а) **Выходной слой n:**

$$\delta_j = \frac{\partial F(S)}{\partial S}\big(T_j - O_j^n\big), \qquad \Delta w_{ij}^n = \eta\,\delta_j\,O_i^{n-1}, \qquad w_{ij}^n \leftarrow w_{ij}^n + \Delta w_{ij}^n.$$

б) **Скрытый слой $n-1$:**

$$\delta_i = \left.\frac{\partial F(S)}{\partial S}\right|_{n-1} \sum_j \delta_j\,w_{ij}^n, \qquad \Delta w_{ki}^{n-1} = \eta\,\delta_i\,O_k^{n-2}, \qquad w_{ki}^{n-1} \leftarrow w_{ki}^{n-1} + \Delta w_{ki}^{n-1}.$$

Ошибка нейрона скрытого слоя находится **умножением производной активационной функции на сумму произведений ошибок нейронов следующего слоя на веса связей** с ними. Так ошибка «распространяется назад» от выхода ко входу.

> **Пояснение.** Для сигмоиды $\dfrac{\partial F}{\partial S} = O(1-O)$, поэтому производная вычисляется прямо по выходу нейрона.

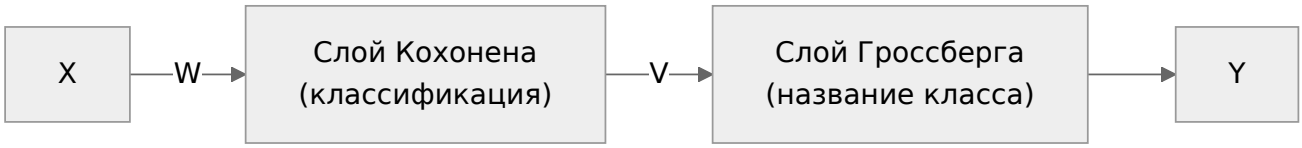
Модификации алгоритма:

1. **Смещение (bias).** Добавляется ещё один вход НС с постоянным уровнем (обычно +1). Его вес подбирается при обучении и позволяет сдвинуть рабочую точку на линейный участок активационной функции.
2. **Импульс (момент).** Для ускорения обучения к изменению веса добавляется доля предыдущего изменения:

$$\Delta w_{ij}(t+1) = \eta\,\delta_j\,O_i + \alpha\,\Delta w_{ij}(t), \qquad \alpha \approx 0{,}9 \text{ — коэффициент импульса.}$$

4.6. Сети встречного распространения

По возможностям такие сети уступают сетям с обратным распространением, но **обучаются на 1–2 порядка быстрее**.



Слой Кохонена работает по принципу **«победитель забирает всё»**: только один нейрон имеет на выходе 1, остальные — 0. Слой разбивает входные векторы на группы похожих. Веса W подстраиваются так, чтобы близкие входные векторы активировали один и тот же нейрон.

- Обучение — **без учителя**: не нужно заранее связывать конкретные нейроны с конкретными объектами; нужно лишь, чтобы несхожие векторы разделялись.
- Правило (v — номер нейрона-победителя, *victory*; α — коэффициент обучения):

$$w_{iv} \leftarrow w_{iv} + \alpha \left(x_i - w_{iv}\right).$$

Геометрически вектор весов победителя поворачивается к входному вектору на долю α разности $X - W$.

- **Начальные веса** нужно задать так, чтобы распределение векторов весов соответствовало плотности входных векторов. Распространённый способ — **метод выпуклой комбинации**: все веса вначале равны $1/\sqrt{n}$ (n — число входов), а каждая компонента входа заменяется на

$$x_i^{\text{corr}} = \beta\, x_i + \frac{1-\beta}{\sqrt{n}}.$$

На первых итерациях $\beta \approx 0$, и все входные векторы совпадают с векторами весов; в ходе обучения β постепенно увеличивают до 1.

Слой Гроссберга обучается **с учителем**:

$$v_{ij} \leftarrow v_{ij} + \beta \left(y_j - v_{ij}\right) k_i,$$

где k_i — выход i-го нейрона слоя Кохонена, y_j — требуемый выход.

В результате веса слоя Гроссберга сходятся к средним значениям желаемых выходов, а веса слоя Кохонена — к средним значениям входов своих кластеров. **Кохонен — классификация; Гроссберг — формирование названия, соответствующего кластеру.**

4.7. Сети Хопфилда

В классической сети Хопфилда выходы нейронов подаются обратно на входы (сеть с обратными связями): слой 0 (распределительный) → слой 1 → обратно на входы.

- Веса связей нейрона с самим собой должны быть нулевыми, иначе сеть будет самовозбуждаться.
- Сеть **устойчива**, если матрица весов симметрична с нулевой диагональю:

$$w_{ij} = w_{ji}, \qquad w_{ii} = 0.$$

Обучение (по Больцману) — в 3 этапа:

1. **Фиксированные вероятности P_{ij}^{+}:**
    1. входным нейронам придаются значения обучающего вектора;
    2. сеть приводится в равновесное состояние;
    3. запоминаются выходы всех нейронов;
    4. п. 1.1–1.3 повторяются для всех обучающих векторов;
    5. вычисляется P_{ij}^{+} — вероятность того, что выходы нейронов i и j оба равны 1.
2. **Нефиксированные (свободные) вероятности P_{ij}^{-}:**
    1. начиная со случайного состояния, сеть приводится к равновесию;
    2. п. 2.1 повторяется многократно, запоминаются выходы всех нейронов;
    3. вычисляется P_{ij}^{-} — вероятность того, что выходы нейронов i и j оба равны 1.
3. **Коррекция весов:**

$$\delta w_{ij} = \eta \left(P_{ij}^{+} - P_{ij}^{-} \right).$$

Процедура повторяется до совпадения фиксированных и нефиксированных вероятностей.

4.8. Проблемы обучения НС

1. Сходимость процедуры обучения доказана только для бесконечного числа итераций при бесконечно малом шаге.
2. **Паралич сети:** рабочие точки нейронов уходят на пологие (насыщенные) участки активационной функции, производная ≈ 0, и обучение практически останавливается. [?]
3. **Локальные минимумы** функции ошибки.
4. Выбор величины **шага** обучения.
5. **Неустойчивость:** обратное распространение требует обучения на конечном (фиксированном) множестве примеров, иначе обучение может не сойтись.

4.9. Стохастические методы обучения

Предусматривают **псевдослучайные изменения весов** с сохранением тех изменений, которые уменьшают ошибку обучения:

1. Задать новые (случайно изменённые) значения весов.
2. Вычислить функцию ошибки по входным и целевым векторам.
3. Если ошибка уменьшилась — изменение сохраняется, иначе — веса корректируются на другие случайные значения.

Концепция: нужно обеспечить выход рабочей точки из области локального минимума в область глобального. Аналогия — шарик на неровной поверхности: если её «трясти» сначала сильно, а потом всё слабее, шарик скорее всего окажется в самой глубокой впадине. Это **имитация отжига**: амплитуда случайных изменений уменьшается по мере снижения параметра T («температуры»).

Больцмановское обучение. Если изменение веса **увеличило** ошибку, его всё равно сохраняют с вероятностью, заданной распределением Больцмана:

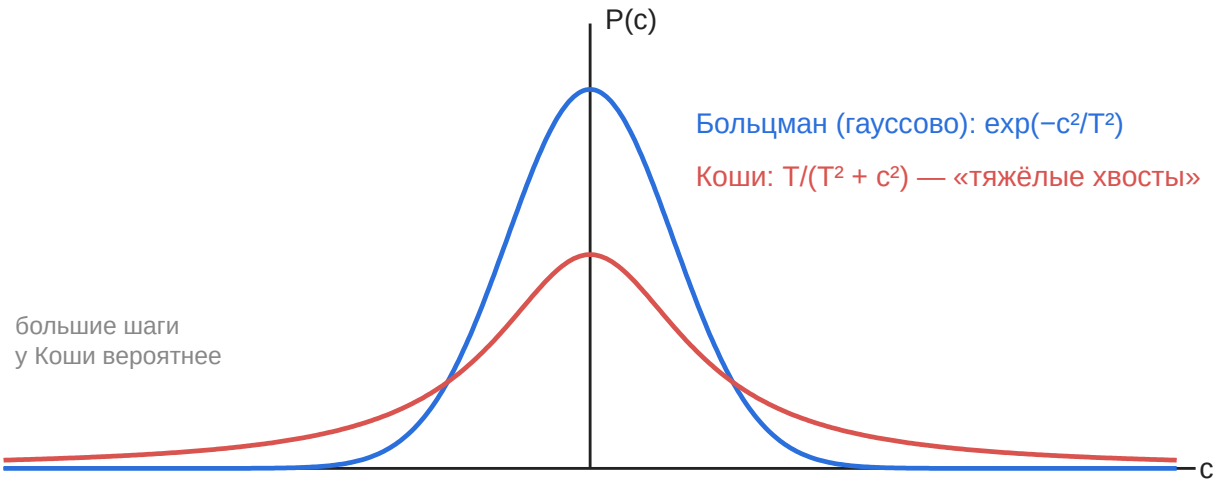
$$P(c) = \exp\left(-\frac{c}{kT}\right),$$

где c — увеличение ошибки, k — константа, T — искусственная температура. С понижением T вероятность принять ухудшение падает.

Обучение Коши. В больцмановском обучении величина случайного шага веса выбирается по гауссову распределению $\exp(-c^2/T^2)$; в обучении Коши его заменяют распределением Коши:

$$P(c) = \frac{T}{T^2 + c^2}.$$

Цель замены — сократить время обучения. У распределения Коши «тяжёлые хвосты»: большие шаги остаются вероятными, и сеть быстрее выходит из локальных минимумов.



> **Пояснение.** Из-за тяжёлых хвостов температуру при обучении Коши можно снижать гораздо быстрее: как $T_0/(1+t)$ вместо $T_0/\ln(1+t)$ у больцмановского обучения.

Краткая сводка

- **Распознавание** — отнесение объекта по его вектору признаков к одному из классов алфавита; **кластеризация** — разбиение объектов на группы без заранее заданных классов.
- **Образ** объекта — набор векторов признаков, полученных в разных условиях наблюдения (например, под разными ракурсами).
- Обязательные функции классификатора: получение первичной информации → формирование вектора признаков → классификация.
- Признаки: физические, структурные, математические; детерминированные и статистические. Хорошие признаки информативны, индивидуальны, инвариантны к условиям наблюдения.
- Из-за шумов распознавание — задача **статистическая**. Оптимальное (байесовское) решение минимизирует средний риск и сводится к сравнению **отношения правдоподобия** f_2/f_1 с **порогом** $\dfrac{P(A_1)(C_{12}-C_{11})}{P(A_2)(C_{21}-C_{22})}$.
- Для двух гауссовских классов с равными дисперсиями, вероятностями и симметричными потерями порог $x_0 = (m_1 + m_2)/2$.
- При единичных потерях байесовское правило = выбор класса с максимальной апостериорной вероятностью $P(A_k)\, f_k(X)$.
- Если априорные вероятности неизвестны — **минимаксная** стратегия: порог, при котором $C_{12}Q_1 = C_{21}Q_2$, и риск не зависит от истинных $P(A_i)$.
- Классификация при заданном числе классов — итеративное перемещение объектов между классами; при неизвестном — последовательное увеличение числа классов или последовательное объединение классов.
- Искусственный нейрон: $O = F(X \cdot W)$; активационные функции — линейная, пороговая, сигмоида, th.
- Один слой реализует только **линейно разделимые** функции (XOR — нет). Два слоя дают выпуклые области, три — области произвольной формы.
- Обучение многослойной сети — **обратное распространение ошибки**: проход вперёд, затем ошибки δ передаются от выхода ко входу, $\Delta w = \eta\, \delta\, O$; ускорение — смещение и импульс.
- Сеть встречного распространения: слой Кохонена (без учителя, «победитель забирает всё») + слой Гроссберга (с учителем); учится на 1–2 порядка быстрее.
- Сеть Хопфилда устойчива при $w_{ij} = w_{ji}$, $w_{ii} = 0$.
- Проблемы обучения: паралич, локальные минимумы, выбор шага, неустойчивость. Стохастические методы (отжиг, Больцман, Коши) помогают выйти из локальных минимумов.